

Faktoren des Fahrrad Verkehrs in Mannheim

Maximilian Samuel Weinhold

Economics, 6. Semester

505314

mweinhol@uni-muenster.de

Hausarbeit im Rahmen des Seminars zur

Analyse von Fahrrad-Verkehrsdaten

Sommersemester 2021

Institut für Verkehrswissenschaft

Dr. Jan Wessel

INHALTSVERZEICHNIS

1. <i>Einleitung</i>	3
2. <i>Literaturüberblick</i>	4
3. <i>Beschreibung der Daten</i>	5
3.1 EcoCounter Mannheim	6
3.2 DWD Daten	7
4. <i>Deskriptive Analyse</i>	11
4.1 Regressionsanalyse	11
5. <i>Fazit</i>	22
6. <i>Anhang</i>	23
<i>Literaturverzeichnis</i>	27

1. EINLEITUNG

Die mobile Infrastruktur urbaner Zentren in Deutschland unterliegt einem Wandel, der nicht mehr allein das Ziel einer autofreundlicheren Stadt hat, sondern auch andere Verkehrsteilnehmer hervor hebt. Im besonderen betrifft diese Entwicklung auch das Fahrrad. So ist laut Nobis (2019) die Anzahl der Fahrradfahrer und die von ihnen zurückgelegten Wege innerhalb von 15 Jahren stark angestiegen und ebenso der Ausbau von Fahrradwegen. Ein Beispiel für diese Entwicklungen ist Mannheim. Denn hier verfolgt die städtische Planung ein 21 Punkte Programm, dass dazu dienen soll den Anteil des Radverkehrs zu steigern.

Im Rahmen dieses Programms installierte die Stadt an verschiedenen Stellen 8 Fahrradzähler, deren stündlichen Zählungen öffentlich abrufbar sind. Mithilfe dieser Daten wollen wir versuchen ein Model zu entwickeln, dass die kausal Einflüsse auf den Radverkehr erklärt und das Aufkommen von Fahrrädern vorhersagen kann. Im besten Fall extrapolieren wir das Model und prüfen, ob wir das Model auch auf Bereiche außerhalb der Zählstellen anwenden können.

Bei diesem Vorhaben bauen wir vornehmlich auf Wessel (2020), der primär untersuchte welchen Einfluss Wettervorhersagen und tatsächliches Wetter auf den Radverkehr in verschiedenen deutschen Städten hat. Dazu nutzen wir Daten des Deutschen Wetter Dienstes.

Darüber hinaus (Wenn Zeit übrig bleibt) wollen wir versuchen die Methoden von Prati et al. (2017) ebenfalls zu verwenden, um ein Model primär zu Vorhersage des extrapolierten Fahrradaufkommens zu entwickeln.

2. LITERATURÜBERBLICK

Da diese Arbeit im Rahmen eines Seminares bei Dr. Jan Wessel entstanden ist, verfolgt diese Arbeit eine ähnliche Methodik wie bei Wessel (2020), der der Frage nachgeht, wie sehr Wettervorhersagen und tatsächliches Wetter einen Einfluss auf das Aufkommen der Fahrradfahrer hat. Dazu entwickelt er ein log-lineares Regressionsmodell, das nicht nur die notwendigen Wetterdaten berücksichtigt, sondern auch andere wesentliche Effekte, wie Feiertage, Schul- und Semesterferien. Sein Modell kommt zu einem adjusted R^2 von 78 %. Die Daten für das Modell stammen von 188 Zählstationen in ganz Deutschland.

Hier noch mehr bearbeiten. Vor allem im Bezug auf die eigene Forschungsfrage.

3. BESCHREIBUNG DER DATEN

Zur Bearbeitung des Models nutzen wir vornehmlich zwei Daten Quellen. Zum einem nutzen wir die Daten der Fahrradzahlstationen Mannheims, die öffentlich im Netz zugänglich sind (Link: <https://mannheim.opendatasoft.com/page/home/>). Hier sind stündliche Werte gezählter Fahrräder verfügbar an 8 verschiedenen Stellen in der Stadt, sowie Längen und Breitengrad der Position, Standortname, Zeit und Datum. Diese Daten verbinden wir mit stündlichen Daten des Deutschen Wetter Dienstes zur Lufttemperatur in 2 Meter Höhe, zur relativen Feuchte, zum Bedeckungsgrad, zum Niederschlag und zur Sonnenstrahlung.

Zhao et al. (2018) und Hong J (2022) zeigen, dass auch Feinstaubbelastung den Radverkehr beeinflussen kann. Und grundsätzlich wären die dazu notwendigen Daten aus Mannheim über Opensensemap.org auch zugänglich, jedoch nicht welche, die weit genug zurückreichen, um den gesamten Betrachtungszeitraum zu beachten. Da Zhao et al. (2018) und Hong J (2022) ihre Forschung in Ostasiatischen Ballungsräumen betrieben haben und in einer Stadt wie Mannheim nicht die selbe Feinstaubbelastung zu erwarten ist, kann man von dieser Variable nicht erhoffen, dass sie die notwendige Erklärungskraft bringt, um einen Wegfall des Betrachtungszeitraumes zu rechtfertigen, weshalb Feinstaubmessungen keinen Weg in den Datensatz gefunden haben. Dafür ist es wichtig Feiertage, Schulferien und Semesterferien zu berücksichtigen. Hier könnte potentiell eine geographische Besonderheit Mannheims eine Rolle spielen, denn das Stadtgebiet grenzt direkt zu zwei verschiedenen Bundesländern an. Zum einem liegt auf dem gegenüberliegenden Rheinufer die Stadt Ludwigshafen, die bereits in Rheinland Pfalz liegt. Zwischen beiden Städten herrscht ein reger Verkehr, weshalb anzunehmen ist, dass voneinander abweichende Feiertage in Rheinland Pfalz und Badenwürttemberg eine

Rolle spielen könnten. Ebenso grenzt Hessen an Mannheim an. Jedoch nicht in einer Reichweite, die für Fahrradfahrer realistisch erscheint und nicht mit einer Stadt, die vergleichbar groß wie Ludwigshafen wäre. Somit finden Feiertage für Hessen keinen Weg ins Model.

Dies gilt ebenso für die Schulferien. Es ist anzunehmen, dass innerhalb Mannheims, Schulen von Mannheimern überwiegend besucht werden, weshalb nur die Schulferien von Baden Württemberg im Datensatz zu finden sind. Neben Schülern fahren ebenso häufig Studenten Fahrrad als günstigstes Verkehrsmittel. Die größte Hochschulbildungseinrichtung ist die Universität Mannheim, deren Semesterferien eine signifikante Rolle spielen dürften.

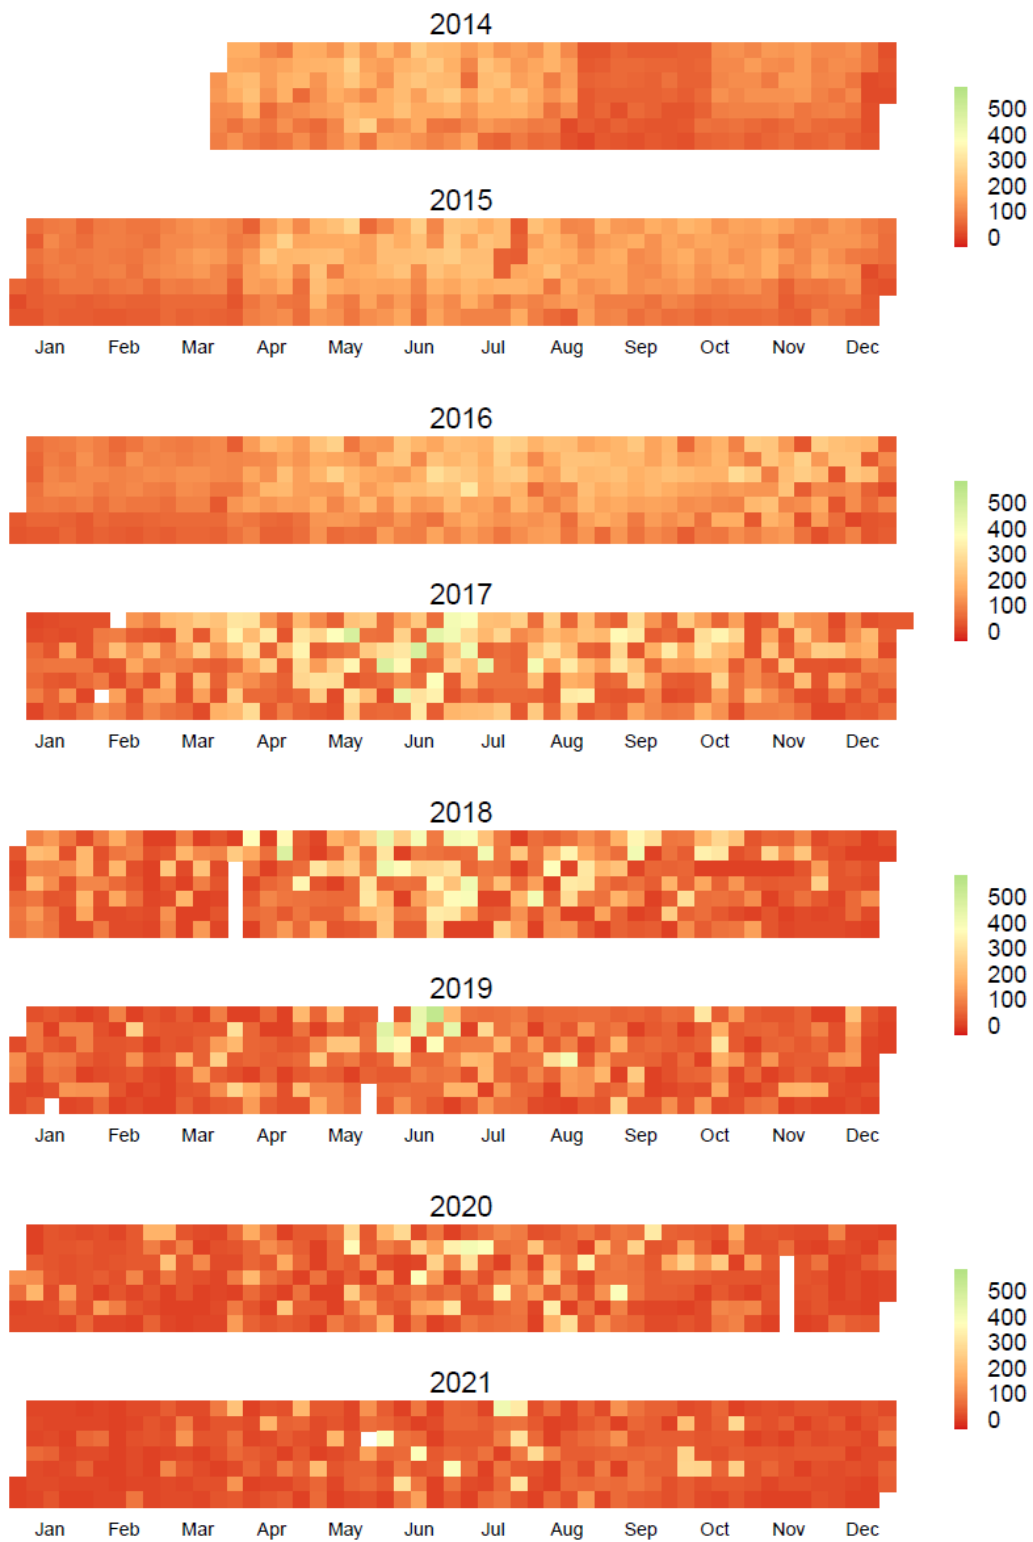
Fügt man all diese Daten zusammen, erhält man einen Datensatz der 410891 Beobachtungen umfasst. Die Ausprägungen pro Tag sind der Darstellung 3.1 zu entnehmen. Dabei fallen zwei Dinge vornehmlich auf. Zum einem sehen wir, wie gegen Ende 2016 die Varianz der Ausprägungen zunimmt. Dies hängt mit der Anzahl der Zählstationen zusammen. Die früheste Zählstation an der Renzstraße ging 2014 in Betrieb. Weiter folgten erst 2016. Je mehr Zählstationen mit unterschiedlichen Verkehrsströmen messen, desto höher ist die tägliche Varianz in den Zählraten. Weiterhin fallen einige wenige weiße Stellen auf. Dies hängt mit unvollständigen Wetterdaten zusammen. Die Menge fehlender Daten fällt hier aber in einen vertretbaren Rahmen, wobei fehlende Tage nicht weiter mit wichtigen Variablen korrelieren.

3.1 *EcoCounter Mannheim*

In Mannheim gibt es 8 verschiedene Stationen. Einen Überblick über diese Stationen ist in Abbildung X zu sehen, wobei zu Erstellung der Graphik ein R Paket genutzt wurde nach Kahle and Wickham (2013). Am Farbgradienten ist zu sehen, wie viele Fahrradfahrer pro Stunde die Zählstationen passieren. Zudem ist der Name der Zählstation eingeblendet zudem das Jahr, seitdem diese Zählstation installiert ist. Die älteste Station hier ist die Renzstraße. Jedoch zählte diese während einer Unterbrechung vom ... bis ... nicht. Weiter Variablen wurden aus den Datumsvariablen erzeugt. So haben wir

eine Dummy Variable für Wochenende eingefügt und eine für Sommermonate. Weiterhin nutzen wir Jahr, Monat, Tag und Stunde als Faktorvariablen, wobei wir nächtliche Stunden zwischen 22 und 5 Uhr ausgeschlossen haben. Zu Abweichungen des Fahrradverkehrs konnte es während Corona kommen, wo Teile des öffentlichen Lebens still standen und damit auch das Verkehrsaufkommen. Deshalb haben wir drei Variablen in das Modell aufgenommen.

3.2 *DWD Daten*

Calendar Heat Map of bicycle traffic in Mannheim*Fig. 3.1:* Heat Map**Quelle:** Ausprägungen des Fahrradaufkommens

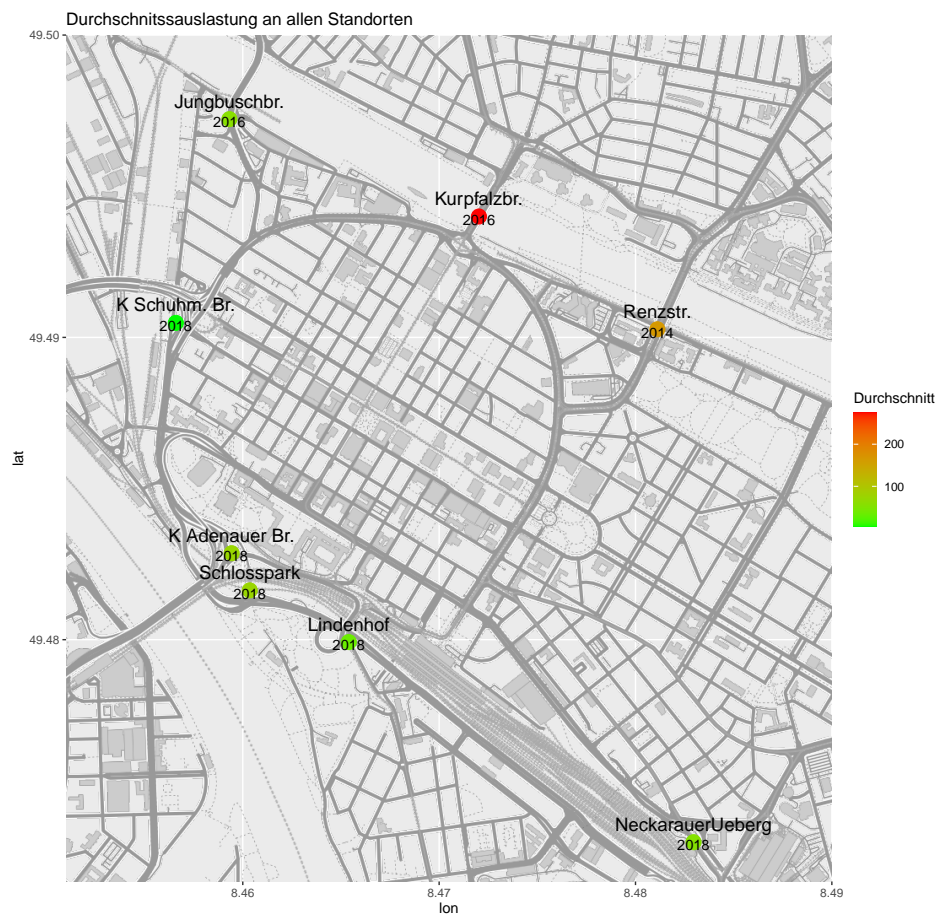


Fig. 3.2: Zählstationsüberblick Mannheim

Quelle: Zählstation nach Durchschnitt pro Stunde und Startjahr




Fig. 3.3: Boxplots zu den Zählstationen

Quelle: Verteilung der Fahrräder pro Stunde

4. DESKRIPTIVE ANALYSE

Name	Min	Durchschnitt	Max	Stand.abw.	Korrelation
Zaehlstand	1	108.35	955	120.21	1
Distanz z Uni	208.36	1122.51	1875.72	583.35	0.26
Wochenende	0	0.28	1	0.45	-0.21
Sommer	0	0.48	1	0.5	0.15
Feiertag BW	0	0.03	1	0.18	-0.09
Feiertag RP	0	0.03	1	0.18	-0.08
Schulferien BW	0	0.32	1	0.47	0.04
Semesterferien	0	0.48	1	0.5	-0.03
WertRR	0	0.07	30.4	0.49	-0.03
QualitaetRR	3	3	3	0	
WertT2M	-13	12.67	39.4	8.33	0.24
QualitaetT2M	3	6.93	7	0.51	0.05
WertF	0.1	3	14.4	1.65	-0.02
QualitaetF	3	9.67	10	1.16	0.1
WertRF	14	69.24	100	20.3	-0.23
QualitaetRF	3	6.93	7	0.51	0.05
WertSD	0	19.22	60	24.82	0.17
QualitaetSD	3	9.33	10	1.42	0.1
WertN	0	5.72	8	3.14	-0.08
QualitaetN	3	3	3	0	
Corona	0	0.42	1	0.49	-0.16
Kontaktbeschr	0	0.11	1	0.32	-0.09
TagesAusbr	0	143.48	687	212.5	-0.17

Notiz für später: Am besten wertest du die Qualitätsdaten genauer aus.

4.1 Regressionsanalyse

Vorerst sind die gesammelten Daten trotz des Umfang recht nutzlos, da sie allein wenig Antworten geben. Durchschnitte und Standardabweichungen ein-

zelner Variablen wie der Temperatur oder des Fahrrad Aufkommens, gäben durchaus Aufschluss nie aber in einem größeren Zusammenhang. Was wir vornehmlich in Erfahrung bringen möchten ist, was den Fahrradverkehr beeinflusst, um daraus folgend Vorhersagen treffen zu können. Dies mündet z.B. in der Frage welchen Einfluss der Regenfall auf den Fahrradverkehr ausübt, oder ob mehr Fahrradfahrer an Feiertagen auf Mannheims Straßen anzufinden sind. Dies wollen wir nicht nur qualitativ beantworten, sondern auch quantitativ.

Ein Mittel um an diese Informationen zu kommen ist die Regressionsanalyse. Diese versucht den Zusammenhang zu messen, in dem zwei Variablen zu einander stehen. So könnte man zb versuchen zu messen, wie sehr die Lufttemperatur in zwei Meter Höhe das Aufkommen von Fahrrädern in Mannheim beeinflusst, dargestellt in der Darstellung 4.1. Mithilfe der Regressionsanalyse kann man nun durch diese in diesem Fall sehr dichte Punktwolke jene Linie ziehen, die das Verhältnis mathematisch am besten repräsentiert. Natürlich verhält sich nicht alles linear zu einander. In der Darstellung sieht man bereits, dass das Fahrradaufkommen bis knapp über 20 °C steigt, danach aber wieder rapide sinkt, das es den Leuten schlicht zu heiß wird. Dies kann manchmal mit einer nicht linearen Funktion dargestellt werden. Aber wie man sieht, egal ob man einen linearen, quadratischen oder kubischen Zusammenhang sieht, die eingezeichneten Regressionslinien erwecken nicht den Eindruck, den wahren Zusammenhang widerzuspiegeln, denn die beobachteten Werte also die eingezeichneten Punkte liegen weit auseinander. Das bedeutet der Fit unseres Models ist gering, allein mit der Außentemperatur können wir die Variation im Fahrradverkehr selbstverständlich nicht erklären.

Nehmen wir weitere Variablen in das Regressionsmodel auf, die den Fahrradverkehr erklären können, wie z.B. Niederschlag oder Ferientage, dann steigt der Fit des Models. Das heißt wir können präzisere Vorhersagen treffen, weil wir uns ein mehrdimensionales Model schaffen. Dies nennt man dann auch die multiple Regressionsanalyse. Lässt man wiederum wichtige Variablen aus, dann kann das auch den die Aussage über die Kausalität verzerren. Deswegen




Fig. 4.1: Fahrrad Daten Mannheim und DWD

Quelle: Graphisches Beispiel einer Regression

ist es wichtig, die richtigen und sinnigen Variablen in das Model aufzunehmen. Jedoch wie geht man bei der Auswahl der Variablen vor?

Zunächst muss man Variablen finden, von denen man argumentieren kann, dass sie die unabhängige Variable den Fahrradverkehr in unserem Fall beeinflussen. Eine Auflistung dieser findet sich in der Übersicht 4. Nehmen wir nicht nur diese Variablen auf, sondern auch die quadratischen oder kubischen Werte oder Intersektionen der verschiedenen Variablen, haben wir einen großen Pool an Variablen, die wir wählen können. Eine naheliegende Vorgehensweise ist es, verschiedene Modelle zu erstellen, die verschiedene Variablen beinhalten und diese zu validieren, um im Vergleich das beste Model für seine Vorhersagen zu nehmen. Natürlich könnte man auch mittels Stepwise Selection das Model erstellen, dies ist ein maschineller Prozesse, der das Model Durchgang für Durchgang mit den Schätzern füllt, die den größten Fit mit sich bringen, ist jedoch auch sehr rechen intensiv, vor allem bei einem

Datensatz dieser Größe.

Stattdessen erstellen wir manuell 30 verschiedene Modelle. Danach zerlegen wir den Datensatz zufällig in einen Trainings Datensatz und in einen Test Datensatz. Der Trainings Datensatz dient dazu, die abhängigen Variablen des Models zu berechnen. Mithilfe des Test Datensatzes versuchen wir die externe Validität des Models zu prüfen, also ob das Model auch zutreffende Aussagen auf Beobachtungswerte treffen kann, mit denen das Model nicht berechnet worden ist. Zur Validierung der 30 Modelle nutzen wir das angepasste Bestimmtheitsmaß $adjR^2$. Das Bestimmtheitsmaß beschreibt wie hoch der Anteil der Streuung der Beobachtungsdaten ist, der durch das Model erklärt werden kann. Je näher das Bestimmtheitsmaß an 1 ist, desto besser fittet das Model, bzw desto besser erklärt das Model die Realität. Um die Modelle zu vergleichen schauen wir das Bestimmtheitsmaß der Modelle im Trainings und Test Datensatz. Dabei kommt die Graphik 4.2 zustande.

Auf der Y-Achse der Graphik 4.2 abgetragen sehen wir die Höhe des Bestimmtheitsmaß. Auf der X Achse sehen wir die Anzahl der Koeffizienten. Mit jedem weiteren Model haben wir weitere Variablen hinzugefügt, angefangen mit den Wetter Variablen, Feiertage, Ferien, Zeitliche Variablen, wie das Jahr, Sommer oder Tageszeit bis hin zur geographischen Lage. Wir sehen, dass das Bestimmtheitsmaß, also die Genauigkeit der Vorhersage des Models, zu nimmt je mehr Variablen wir hinzufügen, bis zu einem Punkt, an dem das Bestimmtheitsmaß im Trainingsdatensatz zwar nochmals bedeutend zu nimmt, im Test Datensatz aber abnimmt. Hier geraten wir ins Overfitting. Das heißt, das Model, das hier entwickelt wurde, kann zwar die Daten, mit denen es trainiert wurde, extrem gut erklären, sobald wir aber mithilfe des Models vorhersagen treffen wollen, auf Grundlage neuer Daten, ist die Genauigkeit der Daten schlechter, als sie sein müsste. Das wollen wir verhindern. Denn wenn wir mit unserem Model Overfitting haben, kann es der Fall sein, dass wir in den Variablen Zusammenhänge sehen, die sich nicht replizieren lassen.

Was löst in unserem Fall das Overfitting aus? Dazu vergleichen wir den




Fig. 4.2: Fahrrad Daten Mannheim und DWD

Quelle: Graphisches Beispiel einer Regression

Regressions Output zweier Modelle in der Tabelle 4.1. Das zweite Model ist jenes, in dem erstmals Overfitting auftritt. Das erste Model ist das Model vor diesem, in dem noch kein Overfitting auftritt.

Tab. 4.1: Log-Lineare Modelle

	<i>Dependent variable:</i>	
	log(Zaehlstand)	
	(1)	(2)
WertT2M	0.027*** (0.001)	0.027*** (0.001)
WertT2M2	0.001*** (0.0001)	0.001*** (0.0001)
WertT2M3	-0.00003*** (0.00000)	-0.00002*** (0.00000)
WertRR	-0.231*** (0.007)	-0.229*** (0.005)
WertRR2	0.029*** (0.001)	0.029*** (0.001)
WertRR3	-0.001*** (0.00004)	-0.001*** (0.00003)
WertF	-0.073*** (0.006)	-0.077*** (0.005)
WertF2	0.008*** (0.002)	0.009*** (0.001)
WertF3	-0.001*** (0.0001)	-0.001*** (0.0001)
WertRF	0.003 (0.002)	0.002 (0.002)
WertRF2	-0.0001*** (0.00003)	-0.0001*** (0.00003)
WertRF3	0.00000***	0.00000***

	(0.00000)	(0.00000)
WertSD	0.0005	0.0005
	(0.001)	(0.001)
WertSD2	−0.00000	0.00001
	(0.00004)	(0.00003)
WertSD3	−0.00000	−0.00000
	(0.00000)	(0.00000)
WertN	0.010	0.008*
	(0.006)	(0.005)
WertN2	−0.005***	−0.005***
	(0.002)	(0.001)
WertN3	0.0003**	0.0004***
	(0.0001)	(0.0001)
FeiertagBW	−0.402***	−0.389***
	(0.026)	(0.019)
FeiertagRP	0.035	0.043
	(0.162)	(0.122)
SchulferienBW	−0.155***	−0.145***
	(0.004)	(0.003)
SemesterferienUM	−0.131***	−0.142***
	(0.003)	(0.003)
Sommer	0.031***	0.024***
	(0.005)	(0.004)
laengengrad	3,000,977.000***	
	(14,623.910)	
laengengrad2	−7,155.153***	
	(34.176)	
breitengrad	493,372.000***	
	(2,544.529)	
laengenbreitengrad	−58,179.300***	
	(300.081)	
as.numeric(Jahr)	31,617.400***	2,480.775
	(2,353.575)	(1,764.690)

as.numeric(Jahr2)	−15.658*** (1.166)	−1.216 (0.874)
as.numeric(Jahr3)	0.003*** (0.0002)	0.0002 (0.0001)
uniMA_dist	−0.013*** (0.0001)	
Stunde06	0.404*** (0.008)	0.404*** (0.006)
Stunde07	0.929*** (0.008)	0.926*** (0.006)
Stunde08	1.078*** (0.009)	1.072*** (0.006)
Stunde09	0.921*** (0.009)	0.915*** (0.006)
Stunde10	0.817*** (0.009)	0.811*** (0.007)
Stunde11	0.882*** (0.009)	0.874*** (0.007)
Stunde12	0.997*** (0.009)	0.990*** (0.007)
Stunde13	1.118*** (0.009)	1.112*** (0.007)
Stunde14	1.172*** (0.009)	1.165*** (0.007)
Stunde15	1.304*** (0.009)	1.297*** (0.007)
Stunde16	1.466*** (0.009)	1.458*** (0.007)
Stunde17	1.470*** (0.009)	1.465*** (0.007)
Stunde18	1.283*** (0.009)	1.281*** (0.006)
Stunde19	1.005***	1.002***

	(0.009)	(0.006)
Stunde20	0.698***	0.698***
	(0.009)	(0.006)
Stunde21	0.635***	0.628***
	(0.050)	(0.037)
Stunde22	0.548***	0.534***
	(0.049)	(0.037)
WochentagDo	−0.007	−0.005
	(0.006)	(0.004)
WochentagFr	−0.084***	−0.083***
	(0.006)	(0.004)
WochentagMi	−0.001	−0.002
	(0.006)	(0.004)
WochentagMo	−0.050***	−0.046***
	(0.006)	(0.004)
WochentagSa	−0.626***	−0.626***
	(0.006)	(0.004)
WochentagSo	−0.970***	−0.968***
	(0.006)	(0.004)
Adenauer-Brücke		0.185***
		(0.004)
Kurpfalzbrücke		1.549***
		(0.004)
K-Schumacher-Brücke		−2.609***
		(0.004)
Lindenhofüberführung		−0.507***
		(0.005)
Neckarauer Übergang		−0.039***
		(0.005)
Renzstraße		0.861***
		(0.004)
Schlosspark Lindenhof		0.180***
		(0.005)

FeiertagBW:FeiertagRP	−0.519*** (0.164)	−0.535*** (0.123)
Constant	−46,216,015.000*** (1,582,933.000)	−1,687,396.000 (1,187,073.000)
Observations	328,715	328,715
R ²	0.668	0.814
Adjusted R ²	0.668	0.814
Residual Std. Error	0.842 (df = 328659)	0.631 (df = 328657)
F Statistic	12,043.5*** (df = 55; 328659)	25,194.4*** (df = 57; 328657)

Note:

*p<0.1; **p<0.05; ***p<0.01

Beide Modelle unterscheiden sich im wesentlichen in der Wahl der Fixed Effects. Fixed Effects sind all jene Schätzer, die über die Zeit nicht variieren, also fix sind und nur zwischen den Entitäten variieren. In diesem konkreten Fall heißt das, ein Fixed Effect ist eine Variable die zeitlich konstant bleibt, sich aber zwischen den Fahrradzahlstationen unterscheidet. Das dient dazu, die Unterschiede zwischen diesen Stationen zu messen und im Model mit aufzunehmen. Denn wenn wir uns die Graphik 3.3 anschauen, sehen wir, dass die Stationen untereinander recht stark variieren. Z.B. sehen wir, dass auf der Kurpfalzbrücke, die von der Innenstadt über den Neckar führt, grundsätzlich mehr Radverkehr herrscht. Nehmen wir jetzt z.B. eine Dummy Variable in das Model auf, die 1 ist, wenn ein Beobachtungswert von der Kurpfalzbrücke stammte und 0 ist, wenn der Beobachtungswert von einer anderen Station stammte, dann erklärt diese Variable den Unterschied zwischen der Kurpfalzbrücke und den anderen Stationen im Model, ohne den Ursächlichen Grund dafür zu kennen, erhöht aber den Fit des Models, denn nun können die anderen Variablen ihren Einfluss präziser schätzen.

Eine solche Dummy Variable können wir für 7 von 8 Stationen in das Model aufnehmen. Bei der achten reicht es, wenn alle anderen Dummy Variablen 0 sind. Andernfalls bekämen wir ein multikolles Model, also ein

Model in dem mindestens zwei Variablen linear abhängig von einander sind. Genau auf diese Weise sind wir im zweiten Model vorgegangen. Dieses beinhaltet eine Dummy Variable Kurpfalzbrücke, Lindenhofüberführung, Neckarauer Übergang, Renzstraße und Schloßpark/Lindenhof. Die übrige Station an der Kurt Schuhmacher Brücke ergibt sich, wie bereits erklärt, wenn alle anderen 7 Dummy Variablen 0 sind. Diese Vorgehensweise führt zu einem Bestimmtheitsmaß von 81,44 %, was sich gut anhört, wie aber bereits gezeigt, größtenteils auf Overfitting zurückzuführen ist.

Möglicherweise hängt dies damit zusammen, dass die Stations Dummy Variablen zwar Unterschiede erkennen, aber keinen ursächlichen Grund dafür finden. Wenn man aber Lageparameter als Fixed Effekt nutzt hätte man einen möglichen ursächlichen Grund für den Unterschied, die Lage. Da Lageparameter zeitlich auch konstant sind, lassen sich diese ebenfalls sehr gut als Fixed Effect nutzen. Im ersten Model nutzen wir dazu den Längengrad, sowie den quadrierten Längengrad, den Breitengrad, Längen und Breitengrad miteinander multipliziert (Intersektion) und den Abstand zur Universität Mannheim in uniMA dist. Auf den quadrierten Wert des Breitengrades verzichten wir, weil dies wiederum zu Multikollinearität führen würde und im Regressionsoutput ein Fehler auftauchen würde, wie sich zeigte. Auch führt eine Kombination aus Lageparametern und Standort Dummy Variablen zu Fehlern im Regressionsoutput, weswegen wir beide Fixed Effects getrennt von einander nutzen.

Obwohl wir bei dem Model mit den Lageparametern ein kleineres Bestimmtheitsmaß von nur 66,8 % erhalten, entscheiden wir uns gegen das Model mit Standort Dummy Variablen, wegen einer höheren externen Validität gemessen im Test Datensatz.

5. FAZIT

6. ANHANG




Fig. 6.1: Korrelations Plot

Quelle: Korrelation zwischen den verschiedenen Variablen

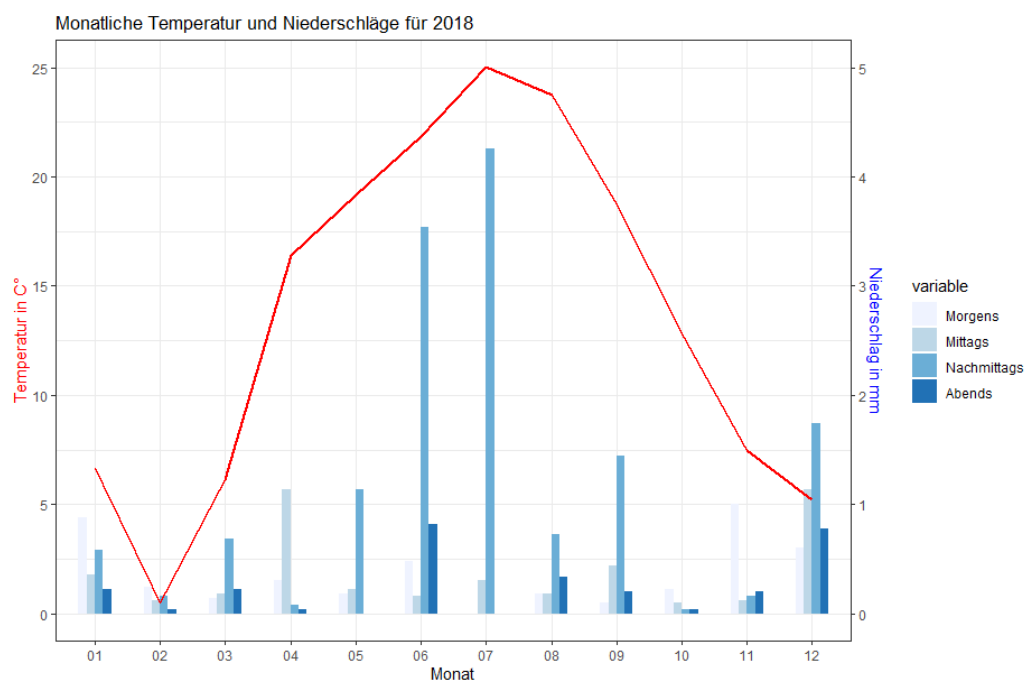


Fig. 6.2: Monatliche Durchschnittliche Temperaturen und maximale Niederschläge nach Tageszeiten in 2018

Quelle: DWD, eigene Darstellung




Fig. 6.3: Tägliche Durchschnitts Temperaturen und monatliche maximale Niederschläge nach Tageszeiten in 2018

Quelle: DWD, eigene Darstellung

LITERATURVERZEICHNIS

- Hong J, McArthur DP, S. J. K. C. (2022). Did air pollution continue to affect bike share usage in seoul during the covid-19 pandemic? *J Transp Health*.
- Kahle, D. and Wickham, H. (2013). Spatial visualization with ggplot2. *The R Journal*, 5(1):144–161.
- Nobis, C. (2019). Mobilität in deutschland - analysen zum radverkehr und fußverkehr. *Studie von Infas, DLR, IVT, und Infas 360 im Auftrag des Bundesministeriums für Verkehr und digitale Infrastruktur*, (70.905/90).
- Prati, G., Pietrantonio, L., and Fraboni, F. (2017). Using data mining techniques to predict the severity of bicycle crashes.
- Wessel, J. (2020). Using weather forecasts to forecast whether bikes are used. *Transportation Research Part A: Policy and Practice*, 138:537–559. Publication status: Published.
- Zhao, P., Li, S., Li, P., Liu, J., and Long, K. (2018). How does air pollution influence cycling behaviour? evidence from beijing. *Transportation Research Part D: Transport and Environment*, 63:826–838.